

Pengembangan Model Analisis Prediktif dari *Big Data* untuk Prediksi Penyakit Jantung Menggunakan Teknik *Machine Learning*

Deo Haganta Depari¹, Irza Ramira Putra², Nadhifa Zhafira³, Quina Alifa⁴

Universitas Pembangunan Nasional Veteran Jakarta

Jl. RS. Fatmawati, Pondok Labu, Jakarta Selatan, 12450, Indonesia.

deohaganta12@gmail.com¹, irzar@upnvj.ac.id², nadhifa@upnvj.ac.id³, quinaalifa@upnvj.ac.id⁴

Abstrak. Diagnosis penyakit jantung memerlukan serangkaian tes untuk mengkonfirmasi apakah seorang pasien mengidap penyakit jantung atau tidak. Penelitian ini dilakukan untuk melihat perbandingan performa model *KNN (K-Nearest Neighbors)*, *SVM (Support Vector Machine)*, *Naive Bayes*, *Decision Tree*, dan Klasifikasi *Random Forest* dalam mengidentifikasi pasien dengan penyakit jantung. Tahapan-tahapan tersebut dimulai dengan mencari *dataset* dan didapatkan *HEART DISEASE DATASET (COMPREHENSIVE)* yang terdiri dari 12 atribut. Kemudian untuk membantu komputasi dan meningkatkan nilai akurasi, dibuat variabel *dummy* dikarenakan atribut *slope* merupakan variabel kategori. Setelah dilakukan normalisasi data, data dibagi menjadi 80% *training* (952 data) dan 20% *testing* (238 data). Proses selanjutnya yaitu pembuatan model yang telah disebutkan sebelumnya kemudian mengevaluasi model-model yang sudah dihasilkan. Setelah dilakukan evaluasi, nilai akurasi tertinggi didapat dengan menggunakan model *Random Forest* yaitu 93.70%. Penelitian ini diharapkan dapat menjadi referensi para peneliti lain untuk menentukan model pengidentifikasian penyakit jantung yang tepat.

Kata Kunci: Penyakit jantung, Random forest

1. Pendahuluan

Center for Disease Control and Prevention menulis bahwa penyakit jantung merupakan penyebab utama meninggalnya pria, wanita dan orang-orang dari sebagian besar kelompok ras dan etnis di Amerika Serikat, dimana paling tidak satu orang meninggal setiap 36 detik dari penyakit jantung [1]. Berdasarkan data Riset Kesehatan Dasar (Riskesdas) tahun 2018, angka kejadian penyakit jantung dan pembuluh darah semakin meningkat dari tahun ke tahun. Setidaknya, 15 dari 1000 orang, atau sekitar 4,2 juta individu di Indonesia menderita penyakit jantung. Penyakit jantung adalah kumpulan penyakit dan kondisi yang menyebabkan masalah kardiovaskular. Setiap jenis penyakit jantung disebabkan oleh hal yang berbeda terhadap kondisi tersebut. Contohnya, Aterosklerosis dan CAD dihasilkan dari penumpukan plak di arteri [1]. Untuk mendiagnosis penyakit jantung, dokter akan melakukan serangkaian tes dan evaluasi, yaitu pemeriksaan fisik, tes darah, tes non-invasif seperti elektrokardiogram, stress test, dll dan tes invasif seperti kateterisasi jantung [2]. Dari tes tersebut didapatkan beberapa data pasien seperti tekanan darah, kadar kolesterol, dan lainnya yang dapat mendukung diagnosis penyakit.

Kesehatan selalu menjadi prioritas bahkan sebelum adanya teknologi. Saat ini industri kesehatan telah berkembang pesat sehingga tersedia banyak ruang untuk penelitian. Sangat penting untuk meningkatkan teknologi perawatan kesehatan yang sudah ada dengan digitalisasi informasi medis, baik dalam hal data yang diberikan pasien maupun hasil rekaman medis yang dihasilkan oleh peralatan medis yang canggih. Kita dihadapkan dengan masalah sulit untuk menguraikan dan menganalisis data besar-besaran yang terkumpul dari hasil revolusi digital ini. Terlepas dari masalah yang ada, beberapa peningkatan teknologi baru memungkinkan data besar dari layanan kesehatan untuk dikonversi menjadi informasi yang berguna dan dapat ditindaklanjuti [3]. Solusi inilah yang dikenal dengan *Big Data Analytics*.


Dengan adanya data yang sangat besar yang kita sebut *big data*, kita bisa menggunakan data yang besar ini di berbagai sektor terutama pada bidang kesehatan, dengan analisa yang tepat, *big data* dapat membantu membawa peningkatan pada layanan kesehatan yang ada sekarang. *Machine Learning* juga menjadi hal yang penting pada peningkatan pelayanan kesehatan dengan *big data*. Dengan adanya *Machine Learning*, kita dapat mempelajari dan bereksperimen dengan metode-metode yang ada untuk menemukan pola atau algoritma yang tepat dalam menemukan penyakit, mencegah penyakit dan banyak hal lain yang dapat membantu meningkatkan kualitas layanan kesehatan yang sudah tersedia saat ini.

Penelitian ini dilakukan dengan mengolah data berdasarkan atributnya untuk mendiagnosis pasien penyakit jantung. Hasil akhir dari penelitian ini adalah perbandingan nilai akurasi dan performa dari beberapa model

klasifikasi, sehingga dapat menentukan model yang tepat. Penelitian ini diharapkan dapat membantu peneliti lain untuk memilih model yang tepat untuk diagnosis penyakit jantung sehingga kedepannya dapat membantu ahli medis.

2. Metode Penelitian

Penelitian ini terdiri dari tahapan yaitu *exploratory data analysis*, praproses data, *modeling*, interpretasi model, evaluasi, dan kesimpulan.



Gambar 1. *Flowchart* metodologi penelitian.

2.1. *Exploratory Data Analysis*

Tujuan dari *Exploratory Data Analysis* adalah untuk mencari tahu informasi lebih mengenai data yang akan kita gunakan dan menjadi ahli pada kumpulan data yang sedang dikerjakan.

2.2. Praproses Data

Pada tahap ini, data yang digunakan akan di praproses agar pada saat klasifikasi hasilnya maksimal, data di praproses melalui tahap seperti normalisasi data, pembagian data training dan testing kemudian transpose matrices.

2.3 Model Klasifikasi

Pada tahap ini kita akan menggunakan data yang telah disiapkan dan membuat berbagai jenis model Klasifikasi, dimana hasil akurasi klasifikasi model-model tersebut akan dibandingkan dan dibuat visualisasi agar terlihat model jenis apa yang memiliki nilai akurasi tertinggi

2.4 Evaluasi Model

Setiap model klasifikasi yang telah dibuat selain dilihat akurasinya juga akan dievaluasi menggunakan *Confusion Matrices* untuk mendapatkan hasil ukuran performa model tersebut.

2.5 Kesimpulan


Dari hasil yang ada, kita dapat menggunakan model klasifikasi dengan nilai akurasi yang terbaik dan juga nilai performa yang terbaik untuk digunakan sebagai model klasifikasi utama, dimana jika ada masukkan data pasien yang baru, kita bisa prediksi dengan model yang sudah ada untuk mengetahui apakah pasien tersebut memiliki penyakit jantung atau tidak, kemudian data pasien yang baru tersebut bisa kita tambahkan ke dalam dataset dimana akan digunakan kedepannya dan setiap prediksi baik benar maupun salah akan dicatat sebagai bahan evaluasi performa model yang digunakan.

3. Pembahasan

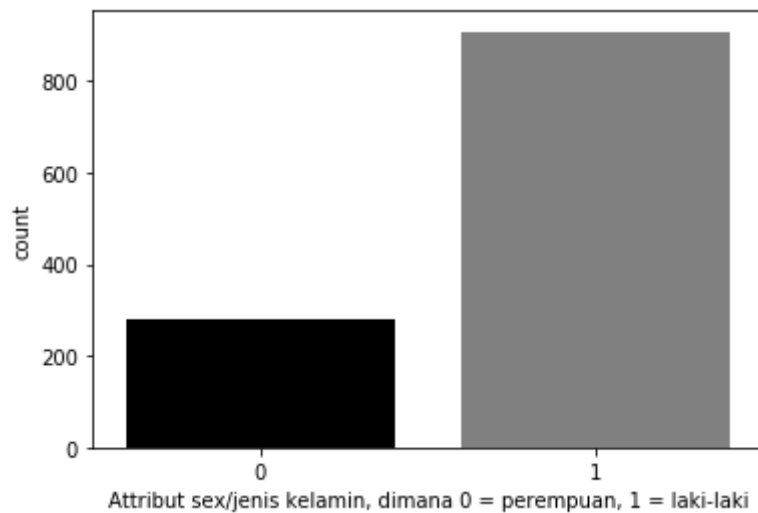
3.1 Exploratory Data Analysis

Penelitian ini menggunakan dataset *HEART DISEASE DATASET (COMPREHENSIVE)* yang telah dimodifikasi dimana data terdiri dari 12 atribut. Data tersebut didapat dari *IEEE*. Informasi atribut data sebagai berikut:

1. *Age* - Umur pasien dalam tahun
2. *Sex* - Jenis Kelamin, angka 1 untuk laki-laki dan 0 untuk perempuan
3. *cp* - *chest pain type* - jenis nyeri dada
 - 1 - *Typical Angina* - nyeri dada yang berhubungan dengan penurunan nya suplai darah ke jantung
 - 2 - *Atypical Angina* - nyeri dada yang tidak berhubungan dengan jantung
 - 3 - *Non-anginal pain* - biasanya kejang esofagus (tidak berhubungan dengan jantung)
 - 4 - *Asymptomatic* - nyeri dada yang tidak menunjukkan tanda-tanda penyakit
4. *trestbps* - *resting blood pressure* - tekanan darah pada istirahat (satuan mmHg pada saat masuk ke rumah sakit), diatas 130-140 akan di menjadi perhatian
5. *chol* - *serum cholesterol in mg/dl* - kolesterol serum dalam satuan mg/dl
 - Serum - $LDL + HDL + 2 * triglycerides$
 - Diatas 200 akan menjadi perhatian
6. *fbs* - *fasting blood sugar* > 120 mg/dl - gula darah puasa, angka 1 untuk true dan 0 untuk false, jika melebihi dari 126 mg/dL maka menandakan diabetes
7. *restecg* - *resting electrocardiographic results* - hasil elektrokardiografi istirahat
 - 0 - tidak ada yang perlu di perhatikan
 - 1 - ST-T kelainan gelombang
 - i. Dapat berkisar dari gejala ringan hingga masalah berat
 - ii. Menandakan detak jantung yang tidak normal
 - 2 - Kemungkinan atau bahkan pasti memiliki hipertrofi ventrikel kiri
 - i. Ruang pemompaan utama pada jantung membesar
8. *thalach* - *maximum heart rate achieved* - detak jantung maksimum tercapai
9. *exang* - *exercise induced angina* - angina akibat olahraga, angka 1 untuk yes/iya dan 0 untuk no/tidak
10. *oldpeak* = *ST depression induced by exercise relative to rest* - ST depresi yang disebabkan oleh olahraga yang relatif terhadap istirahat, dimana dapat terlihat stress jantung selama latihan, jantung yang tidak sehat akan lebih stress
11. *slope* - *the slope of the peak exercise ST segment* - kemiringan dari puncak latihan segmen ST
 - 1 - *Upsloping* - detak jantung yang lebih baik dengan olahraga (tidak umum)
 - 2 - *Flat Sloping* - perubahan yang minim (tipikal jantung yang sehat)
 - 3 - *Downsloping* - tanda jantung yang tidak sehat
12. *target* - *mempunyai penyakit atau tidak, dimana angka 1 yes/ya dan 0 no/tidak (hasil prediksi atribut)*



Gambar 2. Total data untuk atribut Target. Persentase Pasien yang memiliki Penyakit Jantung = 52.82%. Persentase Pasien yang tidak memiliki Penyakit Jantung = 47.18%



Gambar 3. Total data untuk atribut *sex/jenis kelamin*. Persentase Pasien Perempuan = 23.63%. Persentase Pasien Laki-Laki = 76.37%

Selanjutnya kita akan lihat informasi mengenai dataset dan melihat apakah ada *missing value* pada data, hasil seperti berikut:

Data columns (total 12 columns):

#	Column	Count	Non-Null	Dtype
0	age	1190	non-null	int64
1	sex	1190	non-null	int64
2	cp	1190	non-null	int64
3	trestbps	1190	non-null	int64
4	chol	1190	non-null	int64
5	fbs	1190	non-null	int64
6	restecg	1190	non-null	int64
7	thalach	1190	non-null	int64
8	exang	1190	non-null	int64
9	oldpeak	1190	non-null	float64
10	slope	1190	non-null	int64
11	target	1190	non-null	int64

dtypes: float64(1), int64(11)
memory usage: 111.7 KB

Dikarenakan tidak ada *missing value* maka proses menangani *missing value* dapat dilewatkan.

3.2 Praproses Data

Dikarenakan atribut *slope* merupakan variabel kategori maka kami membuat dummy variabel nya, memasukkan dummy variabel dan menghilangkan variabel aslinya, pada *dataframe* akan terlihat seperti ini:

slope_1	slope_2	slope_3
1	0	0
0	1	0
1	0	0
0	1	0
1	0	0
1	0	0

Gambar 4. Atribut *slope* pada *data frame* setelah diganti dengan dummy variable

Dimana jika *slope_n* bernilai 1 berarti *slope* bernilai n dan atribut *slope* lainnya bernilai 0, contoh seperti *slope_2* bernilai satu, maka *slope* bernilai 2 dan *slope_1* dan *slope_3* bernilai 0.

Proses ini dilakukan untuk membantu komputasi dan meningkatkan nilai akurasi dengan atribut 'slope' (variable kategori).

Lalu kami membagi data menjadi dua bagian, yaitu:

- data fitur yang berisikan data dengan atribut : *age, sex, cp, trestbps, chol, fbs, restecg, thalach, exang, oldpeak, slope*.
- Data kelas yang berisikan data dengan atribut : *target*

Kemudian dilakukan Normalisasi Data dengan rumus :

$$X_{\text{changed}} = \frac{X - X_{\min}}{X_{\max} - X_{\min}} \dots\dots\dots (1)$$


3.3 Pembagian Data

Pada proses pembagian data dilakukan pemisahan data untuk training dan testing. 80% training, 20% testing, terbagi menjadi 952 data training, 238 data testing.

3.4 Pembuatan Model

Model yang digunakan yaitu KNN (K-Nearest Neighbors), SVM (Support Vector Machine), Naive Bayes, Decision Tree, dan Klasifikasi Random Forest.


Pada model KNN kami melakukan percobaan dengan nilai K dari 1 hingga 19, setiap nilai akurasi kemudian disimpan dan dibuat visualisasi nya agar terlihat berapa skor akurasi pada nilai k tertentu, proses ini dilakukan untuk mendapatkan nilai k yang menghasilkan akurasi terbaik



Gambar 5. Hasil akurasi model KNN pada nilai K = 1 hingga K = 19

Pada visualisasi terlihat jelas bahwa nilai k pada 1 menghasilkan akurasi terbaik yaitu 79.83%.

Hasil dari setiap model kemudian akan disimpan dan dibuat visualisasi perbandingan akurasi antara model seperti berikut:



Gambar 6. Perbandingan akurasi pada model-model yang digunakan

Akurasi setiap model seperti berikut:

- Akurasi KNN : 79.83%
- Akurasi SVM : 70.17%
- Akurasi Naive Bayes : 83.19%
- Akurasi Decision Tree : 91.18%
- Akurasi Random Forest : 93.70%

Maka terlihat bahwa model Random Forest memiliki nilai akurasi tertinggi.

3.5 Evaluasi Hasil

Proses selanjutnya yaitu evaluasi dari model-model yang sudah dihasilkan. Evaluasi yang dihasilkan adalah *Precision*, *Recall*, dan *F1-Score* dengan *Confusion Matrix*.

Confusion Matrix terdiri dari *TP*(*True Positive*), *FP*(*False Positive*), *FN*(*False Negative*) dan *TN*(*True Negative*), dimana:

- TP: jumlah kasus dimana pasien diprediksi mempunyai penyakit (*predicted positive*) dan nilai sebenarnya pasien memiliki penyakit (*actual positive*)
- FP: jumlah kasus dimana pasien diprediksi mempunyai penyakit (*predicted positive*) dan nilai sebenarnya pasien tidak memiliki penyakit (*actual negative*)

- FN: jumlah kasus dimana pasien diprediksi tidak mempunyai penyakit (*predicted negative*) dan nilai sebenarnya pasien memiliki penyakit (*actual positive*)
- TN: jumlah kasus dimana pasien diprediksi tidak mempunyai penyakit (*predicted negative*) dan nilai sebenarnya pasien tidak memiliki penyakit (*actual negative*)

Precision berarti rasio prediksi benar positif dibandingkan dengan jumlah hasil yang diprediksikan sebagai positif, sehingga dapat diartikan sebagai “berapa banyak pasien yang mempunyai penyakit dari jumlah pasien yang diprediksi mempunyai penyakit.

Dengan Rumus:

$$\text{Precision} = (\text{TP}) / (\text{TP} + \text{FP}) \dots\dots\dots (2)$$

Recall berarti rasio prediksi benar positif dibandingkan dengan jumlah hasil yang benar positif, sehingga dapat diartikan sebagai “berapa banyak pasien yang diprediksi mempunyai penyakit dari jumlah pasien yang benar mempunyai penyakit.

Dengan Rumus:

$$\text{Precision} = (\text{TP}) / (\text{TP} + \text{FN}) \dots\dots\dots (3)$$

F1-Score merupakan nilai perbandingan rata-rata *precision* dan *recall* yang diberikan bobot.

Dengan Rumus:

$$\text{F1 Score} = 2 * (\text{Recall} * \text{Precision}) / (\text{Recall} + \text{Precision}) \dots\dots\dots (2)$$

Support adalah jumlah munculnya kelas sebenarnya dalam kumpulan data yang sudah ditentukan. Jika *support* tidak seimbang dalam data pelatihan maka ini menunjukkan adanya kelemahan struktural dalam skor mengklasifikasi yang dilaporkan dan dapat menunjukkan bahwa perlu mengambil sampel yang bertingkat atau perlunya penyeimbangan.

3.5.1 Evaluasi KNN (K-Nearest Neighbors)

Tabel 1. Hasil Evaluasi model KNN dengan Data Training

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	1.0	1.0	1.0	1.0	1.0
Recall	1.0	1.0	1.0	1.0	1.0
F1-Score	1.0	1.0	1.0	1.0	1.0
Support	459.0	492.0	1.0	951.0	951.0

Tabel 2. Hasil Evaluasi model KNN dengan Data Testing

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	0.76	0.82	0.80	0.79	0.80
Recall	0.76	0.82	0.80	0.79	0.80
F1-Score	0.76	0.82	0.80	0.79	0.80
Support	102.00	136.00	0.80	238.00	238.00

Tabel 3. Confusion Matrix dengan Model KNN

Train Data		Test Data				
	Actually	Actually			Actually	Actually

	Positive	Negative			Positive	Negative
Predicted Positive	459	0		Predicted Positive	78	24
Predicted Negative	0	492		Predicted Negative	24	112

3.5.2 Evaluasi SVM (Support Vector Machine)

Tabel 4. Hasil Evaluasi model SVM dengan Data Training

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	0.68	0.75	0.71	0.71	0.72
Recall	0.76	0.67	0.71	0.71	0.72
F1-Score	0.72	0.71	0.71	0.71	0.72
Support	459.00	492.00	0.71	951.00	951.00

Tabel 5. Hasil Evaluasi model SVM dengan Data Testing

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	0.62	0.79	0.70	0.70	0.71
Recall	0.76	0.65	0.70	0.71	0.70
F1-Score	0.68	0.71	0.70	0.70	0.70
Support	102.00	136.00	0.70	238.00	238.00

Tabel 6. Confusion Matrix model SVM

Train Data				Test Data		
	Actually Positive	Actually Negative			Actually Positive	Actually Negative
Predicted Positive	350	109		Predicted Positive	78	24
Predicted Negative	160	332		Predicted Negative	48	88

3.5.3 Evaluasi Naive Bayes

Tabel 7. Hasil Evaluasi model Naive Bayes dengan Data Training

	0	1	Accuracy	Macro Avg	Weighted Avg
--	---	---	----------	-----------	--------------

Precision	0.82	0.86	0.84	0.84	0.84
Recall	0.85	0.82	0.84	0.84	0.84
F1-Score	0.83	0.84	0.84	0.84	0.84
Support	459.00	492.00	0.84	951.00	951.00

Tabel 8. Hasil Evaluasi model Naive Bayes dengan Data Testing

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	0.83	0.90	0.87	0.87	0.87
Recall	0.87	0.87	0.87	0.87	0.87
F1-Score	0.85	0.88	0.87	0.87	0.87
Support	102.00	136.00	0.87	238.00	238.00

Tabel 9. Confusion Matrix model Naive Bayes

Train Data				Test Data		
	Actually Positive	Actually Negative			Actually Positive	Actually Negative
Predicted Positive	391	68		Predicted Positive	89	13
Predicted Negative	88	404		Predicted Negative	18	118

3.5.4 Evaluasi Decision Tree

Tabel 10. Hasil Evaluasi model Decision Tree dengan Data Training

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	1.0	1.0	1.0	1.0	1.0
Recall	1.0	1.0	1.0	1.0	1.0
F1-Score	1.0	1.0	1.0	1.0	1.0
Support	459.0	492.0	1.0	951.0	951.0

Tabel 11. Hasil Evaluasi model Decision Tree dengan Data Testing

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	0.89	0.90	0.89	0.89	0.89
Recall	0.86	0.92	0.89	0.89	0.89
F1-Score	0.88	0.91	0.89	0.89	0.89
Support	102.00	136.00	0.89	238.00	238.00

Tabel 12. Confusion Matrix model Decision Tree

Train Data			Test Data			
	Actually Positive	Actually Negative			Actually Positive	Actually Negative
Predicted Positive	459	0		Predicted Positive	88	14
Predicted Negative	0	492		Predicted Negative	11	125

3.5.5 Evaluasi Random Forest

Tabel 13. Hasil Evaluasi model Random Forest dengan Data Training

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	1.0	1.0	1.0	1.0	1.0
Recall	1.0	1.0	1.0	1.0	1.0
F1-Score	1.0	1.0	1.0	1.0	1.0
Support	459.0	492.0	1.0	951.0	951.0

Tabel 14. Hasil Evaluasi model Random Forest dengan Data Testing

	0	1	Accuracy	Macro Avg	Weighted Avg
Precision	0.97	0.92	0.94	0.95	0.94
Recall	0.90	0.98	0.94	0.94	0.94
F1-Score	0.93	0.95	0.94	0.94	0.94
Support	102.00	136.00	0.94	238.00	238.00

Tabel 15. Confusion Matrix model Random Forest

Train Data			Test Data		
	Actually Positive	Actually Negative		Actually Positive	Actually Negative
Predicted Positive	459	0	Predicted Positive	91	11
Predicted Negative	0	492	Predicted Negative	3	133

4. Penutup

Berdasarkan hasil kegiatan yang sudah dilakukan, dapat ditarik beberapa kesimpulan dan saran. Pada bagian ini, akan dibahas kesimpulan dari hasil kegiatan, dan saran untuk kegiatan selanjutnya yang merupakan kekurangan pada kegiatan ini.

4.1 Kesimpulan

Setelah dilakukan penelitian terhadap data pasien penyakit jantung dari IEEE *dataset* untuk mengembangkan model klasifikasi yang tepat untuk diagnosis pasien penyakit jantung. Proses yang dilakukan dibagi menjadi beberapa tahap, dimulai dari fase pertama yaitu praproses data dengan tahapan normalisasi data, pembagian data training dan testing kemudian transpose matrices. Pada proses pembagian data menghasilkan 952 data training, 238 data testing. Lalu pada fase kedua dilakukan proses pembuatan model dan evaluasi dari model yang telah dibuat, yaitu KNN (K-Nearest Neighbors), SVM (Support Vector Machine), Naive Bayes, Decision Tree, dan Klasifikasi Random Forest. Hasil evaluasi model, nilai akurasi tertinggi didapat dengan menggunakan model Random Forest yaitu 93.70%, diikuti oleh model Decision Tree dengan nilai akurasi 91.18%, lalu model Naive Bayes dengan nilai akurasi 83.19%, model KNN dengan nilai akurasi 79.83%, dan model SVM dengan nilai akurasi terendah yaitu 70.17%. Sehingga dapat disimpulkan bahwa berdasarkan penelitian ini, model Random Forest yang paling tepat untuk digunakan untuk diagnosis pasien penyakit jantung.

4.2 Saran

Untuk penelitian selanjutnya dapat dibuat dimana hasil prediksi dari data pasien dapat disimpan ke dalam dataset utama yang tentunya sudah di validasi oleh ahli medis dan juga sudah diberikan izin oleh pasien untuk digunakan, sehingga data akan menjadi lebih besar dan bervariasi, hasil dari penelitian ini kemudian diharapkan dapat digunakan secara langsung oleh para ahli medis dan dapat membantu ahli medis.

REFERENSI

- [1] Donovan, et al. Healthline (2018). Everything You Need to Know about Heart Disease.
- [2] Higuera, et al. Healthline (2018). How Is Heart Disease Diagnosed?
- [3] NEJM Catalyst (2018). Healthcare Big Data and the Promise of Value-Based Care.
- [4] Narkhede. Towards data science (2018). Understanding Confusion Matrix.
- [5] The scikit-yl developers (2016). Classification Report - Yellowbrick v1.3.post1 documentation.